

Sujet Examen

Prédiction des retards d'avion

Introduction

Les retards de vols constituent une problématique majeure dans le secteur aérien, impactant non seulement les passagers mais aussi les compagnies aériennes et les aéroports. Selon le Bureau of Transportation Statistics des États-Unis, environ 19 % des vols ont été retardés en 2019, engendrant des coûts économiques estimés à 28 milliards de dollars.

Ces retards peuvent entraîner des désagréments tels que des correspondances manquées, une insatisfaction (forte) des clients et des perturbations opérationnelles. Ils résultent de divers facteurs, notamment les conditions météorologiques, la congestion du trafic aérien, des problèmes techniques ou opérationnels.

Face à cette complexité, le recours à des approches basées sur les données, telles que l'analyse prédictive, devient essentiel pour anticiper et gérer efficacement les retards. Ces techniques permettent d'analyser des données historiques et potentiellement en temps réel pour identifier les causes des retards, estimer leur probabilité et leur durée, et pouvoir optimiser les décisions opérationnelles.

C'est pourquoi le Bureau of Transportation Statistics des États-Unis a mis à disposition un jeu de données, afin de démontrer comment le machine learning peut être utilisé pour anticiper les retards de vols, améliorer la satisfaction des passagers et optimiser les opérations des compagnies aériennes.

L'objectif principal de ce projet est de développer un modèle de classification capable de prédire si un vol sera retardé de plus de 15 minutes à l'arrivée. Cette prédiction binaire (retardé ou non) est cruciale pour améliorer la planification des vols, informer les passagers en temps réel et réduire les coûts associés aux retards.

Sujet : construire et déployer un modèle capable d'effectuer une prédiction des retards d'avion.

En tant que professionnel de la Data vous serez particulièrement attentif à maintenir l'infrastructure nécessaire au déploiement continu d'une industrialisation d'un modèle de prédiction de retards de vols mais également d'industrialiser le processus d'ETL nécessaire à la préparation des données. Pour ce faire, vous pouvez utiliser un outil externe, complémentaire à Python si vous le souhaitez, en tenant compte des risques, des menaces mais également des aspects éthiques et légaux des données lors du stockage mais également lors de l'exploitation.

Concernant le stockage des données en amont, les questions d'historisation des données et plus particulièrement des retards sera anticipé en amont afin de pouvoir répondre aux problématiques. Chaque étape de construction du modèle relationnel (constructions des tables de faits et de dimensions, modèle relationnel des données, etc) sera documenté et optimisé pour anticiper les montées en charge.

Vous devrez de la même manière, utiliser un algorithme d'IA que vous allez paramétrer afin de répondre à la problématique.

Le jeu de données à votre disposition

Voici une explication détaillée des variables (dont vous aurez besoin, mais attention à bien mentionner celles que vous conserverez), issues du jeu de données sur les retards de vols fourni par le Bureau of Transportation Statistics (BTS) des États-Unis.

Ce jeu de données contient plusieurs fichiers : 1 par mois.

Variables temporelles

- **DAY_OF_WEEK** : Jour de la semaine (1 = lundi, 7 = dimanche)
- **FL_DATE** : Date complète du vol (format AAAA-MM-JJ)

Informations sur le vol

- **UNIQUE_CARRIER** : Code unique du transporteur (ex. : 'AA' pour American Airlines)
- **AIRLINE_ID** : Identifiant numérique de la compagnie aérienne
- **CARRIER** : Code du transporteur
- **TAIL_NUM** : Numéro de queue de l'avion
- **FL_NUM** : Numéro du vol

Aéroport d'origine

- **ORIGIN_AIRPORT_ID** : Identifiant de l'aéroport d'origine
- **ORIGIN_AIRPORT_SEQ_ID** : Identifiant de séquence de l'aéroport d'origine
- **ORIGIN_CITY_MARKET_ID** : Identifiant du marché de la ville d'origine
- **ORIGIN** : Code IATA de l'aéroport d'origine (ex. : 'JFK')
- **ORIGIN_CITY_NAME** : Nom de la ville d'origine
- **ORIGIN_STATE_ABR** : Abréviation de l'État d'origine
- **ORIGIN_STATE_FIPS** : Code FIPS de l'État d'origine
- **ORIGIN_STATE_NM** : Nom complet de l'État d'origine
- **ORIGIN_WAC** : Code de zone de l'aéroport d'origine

Aéroport de destination

- **DEST_AIRPORT_ID** : Identifiant de l'aéroport de destination

- **DEST_AIRPORT_SEQ_ID** : Identifiant de séquence de l'aéroport de destination
- **DEST_CITY_MARKET_ID** : Identifiant du marché de la ville de destination
- **DEST** : Code IATA de l'aéroport de destination
- **DEST_CITY_NAME** : Nom de la ville de destination
- **DEST_STATE_ABR** : Abréviation de l'État de destination
- **DEST_STATE_FIPS** : Code FIPS de l'État de destination
- **DEST_STATE_NM** : Nom complet de l'État de destination
- **DEST_WAC** : Code de zone de l'aéroport de destination

Horaires et retards

- **CRS_DEP_TIME** : Heure de départ prévue (au format HHMM)
- **DEP_TIME** : Heure réelle de départ
- **DEP_DELAY** : Retard au départ en minutes (négatif si en avance)
- **DEP_DELAY_NEW** : Retard au départ, avec 0 pour les retards ≤ 0
- **DEP_DEL15** : Indicateur de retard au départ ≥ 15 minutes (1 = oui, 0 = non)
- **DEP_DELAY_GROUP** : Groupe de retard au départ (par tranches de 15 minutes)
- **DEP_TIME_BLK** : Plage horaire du départ (ex. : '0600-0659')
- **TAXI_OUT** : Temps de roulage avant le décollage (en minutes)
- **WHEELS_OFF** : Heure de décollage (roues quittant le sol)
- **WHEELS_ON** : Heure d'atterrissage (roues touchant le sol)
- **TAXI_IN** : Temps de roulage après l'atterrissage (en minutes)
- **CRS_ARR_TIME** : Heure d'arrivée prévue
- **ARR_TIME** : Heure réelle d'arrivée
- **ARR_DELAY** : Retard à l'arrivée en minutes
- **ARR_DELAY_NEW** : Retard à l'arrivée, avec 0 pour les retards ≤ 0
- **ARR_DEL15** : Indicateur de retard à l'arrivée ≥ 15 minutes (1 = oui, 0 = non)
- **ARR_DELAY_GROUP** : Groupe de retard à l'arrivée (par tranches de 15 minutes)
- **ARR_TIME_BLK** : Plage horaire de l'arrivée (ex. : '0900-0959')

Annulations et détournements

- **CANCELLED** : Indicateur d'annulation du vol (1 = oui, 0 = non)
- **CANCELLATION_CODE** : Code de la raison de l'annulation (A = transporteur, B = météo, C = NAS, D = sécurité)
- **DIVERTED** : Indicateur de vol détourné (1 = oui, 0 = non)

Durées et distances

- **CRS_ELAPSED_TIME** : Durée prévue du vol (en minutes)
- **ACTUAL_ELAPSED_TIME** : Durée réelle du vol (en minutes)
- **AIR_TIME** : Temps de vol effectif (en minutes)

Rappel des compétences qui doivent être démontrés :

- C1. Identifier un jeu de données pour répondre aux besoins métiers et aux cas d'usage, en tenant compte des enjeux de pertinence et de cohérence.
- C2. Identifier les risques éthiques et sociétaux à prendre en compte dans le cadre de l'exploitation de la solution d'IA pour prévenir les dérives éventuelles, en tenant compte du cadre réglementaire.
- C3. Préparer les données pour renforcer leur intégrité et leur pertinence en vue du développement de la solution IA, en mobilisant les techniques de traitement adaptées et en tenant compte des attendus (besoins métiers, cas d'usage etc.) identifiés en phase de cadrage du projet.
- C4. Choisir un modèle IA pour disposer d'une solution adaptée et performante par rapport aux cas d'usage, en mesurant sa pertinence et en mobilisant une démarche scientifique.
- C5. Entraîner le modèle d'IA de façon automatique et supervisée pour valider la pertinence des solutions envisagées, au regard des cas d'usage énoncés par le métier.
- C6. Implémenter le modèle d'IA en intégrant les briques technologiques (moteurs, reporting, suivi des prévisions etc.) au sein de l'environnement technique choisi pour exploiter la solution.
- C8. Mesurer la performance et les impacts de la solution d'IA pour maintenir son application fonctionnelle, conformément aux cas d'usage et aux enjeux identifiés.

- C9. Adopter une démarche d'amélioration continue de la solution IA, pour garantir son évolution au fil du temps, dans le respect des exigences de la commande initiale et en tenant compte des évolutions des besoins utilisateurs et des données mobilisables.